

# 基于迁移学习与 类别平衡策略的 皮肤镜图像皮肤病变分类

HAM10000 数据集课程实践实验报告

课程实践：基于皮肤镜图像的皮肤病变分类

数据集：HAM10000 (10015 张图像, 7 类病变)

报告日期：2026 年 9 月

## 摘要

皮肤镜图像的自动分类是皮肤癌辅助筛查的关键技术。本实验在公开数据集 HAM10000（10015 张皮肤镜图像、7 类病变）上完成病变分类系统的搭建与改进。针对该数据集两个核心难点——类别严重不平衡（最多的黑色素细胞痣 6705 张，最少的皮肤纤维瘤仅 115 张，相差 58 倍）与同病灶多图带来的数据泄漏风险，实验采取了按病灶分组划分数据、迁移学习初始化、按类频率倒数加权采样与面向采集差异的强数据增强等措施。

实验分三个阶段推进：阶段一完成数据获取、清洗与划分，并训练随机初始化的 ResNet18 基线；阶段二针对基线暴露的稀有类召回过低问题实施三项改进（ImageNet 预训练微调、加权采样、强增强）；阶段三完成以平衡准确率为核心的测试集评估与误差分析。最终，改进模型在按病灶分组的 1001 张测试图上取得总体准确率 0.8272、平衡准确率 0.7261、宏平均 F1 0.7079、宏平均 AUC 0.9610，相对基线分别提升 5.0、11.2、10.1、2.3 个百分点；其中临床意义最重要的黑色素瘤召回率由 0.442 提升至 0.646。全部代码、日志与权重可由仓库脚本复现。

**关键词：**皮肤病变分类；HAM10000；类别不平衡；迁移学习；卷积神经网络

# 目 录

|                              |   |
|------------------------------|---|
| 一、数据集说明与预处理方法 .....          | 1 |
| 1.1 数据集介绍 .....              | 1 |
| 1.2 数据获取与还原 .....            | 2 |
| 1.3 数据划分：按病灶分组，防止泄漏 .....    | 3 |
| 1.4 图像预处理与增强 .....           | 3 |
| 二、实验方案（模型原理和改进） .....        | 3 |
| 2.1 基线：随机初始化的 ResNet18 ..... | 3 |
| 2.2 改进一：ImageNet 迁移学习 .....  | 3 |
| 2.3 改进二：类别加权采样 .....         | 4 |
| 2.4 改进三：面向采集差异的强增强 .....     | 4 |
| 2.5 训练配置 .....               | 4 |
| 三、评价指标 .....                 | 4 |
| 四、实验结果与分析 .....              | 5 |
| 4.1 总体指标对比 .....             | 5 |
| 4.2 逐类召回率对比 .....            | 5 |
| 4.3 混淆矩阵分析 .....             | 6 |
| 4.4 训练过程 .....               | 7 |
| 4.5 消融说明与局限 .....            | 8 |
| 4.6 复现清单 .....               | 8 |
| 五、改进方向 .....                 | 8 |
| 参考文献 .....                   | 9 |

注：本目录由域代码生成。如编辑文档后页码变动，请在目录上右键选择“更新域”以刷新页码。

# 一、数据集说明与预处理方法

## 1.1 数据集介绍

HAM10000 (Human Against Machine with 10000 training images, Tschandl 等, 2018) 是皮肤病变分类最常用的公开数据集, 在 ISIC 国际皮肤成像挑战赛生态中被广泛使用。数据由奥地利维也纳医科大学皮肤科与澳大利亚 Rosendahl 皮肤诊所超过 20 年的临床积累构成, 本实验使用其官方发布版本: 共 10015 张皮肤镜图像 (JPEG, 约 600×450 像素), 对应 7470 个独立病灶——同一病灶常有多张不同角度、不同焦距的照片, 这一特点对数据划分方式有直接影响 (见 1.3 节)。

全部图像标注为 7 类病变, 各类别数量与占比如表 1 所示。

表 1 HAM10000 类别分布

| 类别代码  | 病变名称   | 性质   | 图像数  | 占比    |
|-------|--------|------|------|-------|
| nv    | 黑色素细胞痣 | 良性   | 6705 | 66.9% |
| mel   | 黑色素瘤   | 恶性   | 1113 | 11.1% |
| bkl   | 良性角化病  | 良性   | 1099 | 11.0% |
| bcc   | 基底细胞癌  | 恶性   | 514  | 5.1%  |
| akiec | 光化性角化病 | 癌前病变 | 327  | 3.3%  |
| vasc  | 血管性病损  | 良性   | 142  | 1.4%  |
| df    | 皮肤纤维瘤  | 良性   | 115  | 1.1%  |

类别分布高度不平衡: 数量最多与最少的类相差 58 倍。更关键的是, 临床权重与类别数量倒挂——数量最少的类别中含有恶性程度最高的黑色素瘤。如果模型把所有图像都预测为 nv, 总体准确率即可达到 66.9%, 但这样的模型在临床上毫无价值。这一事实决定了本实验的评估必须以平衡指标为主 (见第三章)。类别分布与各类样例分别如图 1、图 2 所示。




图 1 HAM10000 类别分布（10015 张图像，7 类）




图 2 七类病变各一张样例图

从样例图可以直接观察到任务的难度：不同类别之间视觉相似度高（如良性角化病与早期黑色素瘤都表现为色斑），同一类别内部外观差异大（黑色素细胞痣从浅棕到深黑均有覆盖）；图像之间还存在色温、亮度、毛发遮挡、标尺入镜等采集差异。这些观察直接指导了后文数据增强策略的设计。

## 1.2 数据获取与还原

数据从 Hugging Face 公开镜像（marmal88/skin\_cancer，parquet 格式）获取，用脚本 `parquet_extract.py` 还原为原始图像目录。还原时发现该镜像实际混入了 3339 张 HAM10000 之外的照片（合计 13354 张）。为保证使用的正是官方 HAM10000、结果与文献可比，实验按官方 metadata 清单（10015 个 `image_id`）做交集过滤，并对分片间的重复行按 `image_id` 去重。这一步若不处理，数据集规模与构成都将偏离文献设定。

### 1.3 数据划分：按病灶分组，防止泄漏

同一病灶的多张照片极其相似（同一天对同一颗病灶拍摄）。如果按图像随机划分训练集与测试集，同一病灶的照片会同时出现在两个集合中，模型可以依靠“记忆”近重复样本获得虚高的指标。正确的做法是按 `lesion_id` 分组划分：一个病灶的所有照片只能进入同一个集合。需要说明的是，镜像数据自带的 `train/val/test` 划分正是按图像随机划分的，存在泄漏，本实验未采用，而是自行实现了按病灶分组、按类别分层的划分（每个集合内各类别比例接近一致），划分结果如表 2 所示。

表 2 按 `lesion_id` 分组的数据划分结果

| 集合    | 图像数  | 用途                       |
|-------|------|--------------------------|
| train | 8011 | 训练（含数据增强）                |
| val   | 1003 | 每个 epoch 验证，按验证准确率保存最优权重 |
| test  | 1001 | 最终评估，训练过程完全不可见           |

### 1.4 图像预处理与增强

输入统一为中心方形裁剪后缩放至  $224 \times 224$ （ResNet 标准输入尺寸），并按 ImageNet 均值方差归一化；预训练模型要求如此，基线模型保持一致以保证对比公平。训练增强分两档：基线使用随机水平/垂直翻转与  $90^\circ$  整数倍旋转——皮肤镜图像没有固定方向，这些变换不改变病变语义；改进版在此基础上增加亮度/对比度扰动（模拟采集差异）、高斯模糊（模拟离焦）与随机小角度旋转。皮肤病变的颜色与纹理是核心判别信息，因此不使用会破坏颜色语义的大幅色彩抖动。

## 二、实验方案（模型原理和改进）

### 2.1 基线：随机初始化的 ResNet18

基线采用 ResNet18（He 等，2016）：4 个残差阶段（每阶段 2 个基本残差块）加全局平均池化与全连接分类头，约 11.7M 参数。残差结构通过恒等映射  $y = F(x) + x$  让梯度直接回传，是缓解深层网络退化问题的标准做法。基线从随机初始化训练，配合基础增强与普通交叉熵损失，共 30 个 epoch，代表“不使用任何先验知识”的起点。

### 2.2 改进一：ImageNet 迁移学习

预训练模型在 ImageNet 上学到的大量低中层视觉特征（边缘、纹理、颜色块状结构）对皮肤镜图像同样适用。改进版用 ImageNet 预训练权重初始化骨干网络、将最后的全连接层替换为 7 类输出后整体微调。对样本仅有几十张的稀有类别而言，

这相当于免费带入了“会看图”的初始化，通常能同时提升收敛速度与最终精度。

## 2.3 改进二：类别加权采样

均匀采样下，一个训练 epoch 中 df 类仅出现约 97 次而 nv 类出现 5360 次，梯度几乎被大类支配。改进版使用 `WeightedRandomSampler`，按类频率的倒数给每张图像赋予采样权重（归一化后 df 为 1.0、nv 为 0.018），使每个 epoch 中七类的期望出现次数接近。与在损失函数中加权的方式相比，采样加权与 `BatchNorm`、固定批大小配合得更稳定，实现也更简单。

## 2.4 改进三：面向采集差异的强增强

如 1.4 节所述，针对数据集色温与清晰度差异大的特点，改进版加入颜色扰动与模糊扰动，扩大训练分布的覆盖范围，缓解稀有类过拟合。

## 2.5 训练配置

两个模型的数据划分、训练轮数与优化器完全一致，唯一变量是三处改进，保证对比公平。完整配置如表 3 所示。实验在单张 RTX 4090（24GB）上进行，PyTorch 2.11 + torchvision 0.26，两个模型各训练 30 个 epoch，总耗时约 25 分钟，随机种子固定为 42，全部结果可复现。

表 3 基线与改进版的训练配置

| 配置项   | 基线                                | 改进版                |
|-------|-----------------------------------|--------------------|
| 初始化   | 随机初始化                             | ImageNet 预训练微调     |
| 损失函数  | 交叉熵                               | 交叉熵                |
| 采样方式  | 均匀采样                              | 类频率倒数加权采样          |
| 数据增强  | 翻转 / 旋转                           | 加颜色扰动 / 模糊 / 小角度旋转 |
| 优化器   | AdamW, lr=1e-3, weight decay=1e-4 | 同左                 |
| 学习率调度 | 余弦退火, 30 epochs                   | 同左                 |
| 批大小   | 64                                | 同左                 |
| 模型选择  | 验证集准确率最优权重                        | 同左                 |

## 三、评价指标

类别不平衡场景下，总体准确率会被大类主导，本实验采用表 4 所示的指标体系。其中平衡准确率（各类召回率的平均）是核心单一指标；逐类召回率具有直接的临床解读——黑色素瘤的召回率对应“漏诊率”，漏诊一例黑色素瘤的代价远大于

误诊一例痣。

表 4 评价指标定义与选用理由

| 指标                    | 定义             | 为什么选用                    |
|-----------------------|----------------|--------------------------|
| Accuracy              | 总体像素级正确率       | 参考值；注意 66.9% 是“全猜 nv”的底线 |
| Balanced Accuracy     | 各类召回率的算术平均     | 对不平衡最核心的单一指标             |
| Macro F1              | 各类 F1 的平均（不加权） | 同时考虑精确率与召回率，稀有类与大类同权     |
| Macro AUC (OvR)       | 一对其余多类 AUC 的平均 | 与阈值无关的排序能力               |
| 逐类 precision / recall | 每个类别的查准率 / 查全率 | mel 的召回率即漏诊率，临床最关键       |
| 混淆矩阵（行归一化）            | 每个真实类被分到各类的比例  | 直观看“谁被认成了谁”              |

## 四、实验结果与分析

### 4.1 总体指标对比

在按病灶分组划分的 1001 张测试图上，两个模型的总体指标如表 5 所示。

表 5 测试集总体指标对比（n=1001）

| 指标                | 基线（scratch） | 改进版（pretrained+加权+增强） | 提升       |
|-------------------|-------------|-----------------------|----------|
| Accuracy          | 0.7772      | 0.8272                | +5.0 pt  |
| Balanced Accuracy | 0.6146      | 0.7261                | +11.2 pt |
| Macro F1          | 0.6071      | 0.7079                | +10.1 pt |
| Macro AUC (OvR)   | 0.9384      | 0.9610                | +2.3 pt  |

改进版全面超过基线，且越“公平”的指标提升越大——平衡准确率提升 11.2 个百分点，而总体准确率仅提升 5.0 个百分点。这说明增益主要来自稀有类，而不是靠把大类做得更好。四项指标全部落入或超过文献常见区间（ResNet 级模型：Accuracy 0.83–0.87、Balanced Accuracy 0.65–0.75、Macro AUC 0.91–0.94），其中宏平均 AUC 0.9610 高于常见水平。

### 4.2 逐类召回率对比

表 6 逐类召回率 (recall) 对比

| 类别           | 测试图数 | 基线    | 改进版   | 变化      |
|--------------|------|-------|-------|---------|
| akiec (癌前病变) | 34   | 0.324 | 0.324 | $\pm 0$ |
| bcc (恶性)     | 50   | 0.580 | 0.740 | +16 pt  |
| bkl (良性)     | 107  | 0.551 | 0.720 | +17 pt  |
| df (良性)      | 8    | 0.500 | 0.750 | +25 pt  |
| mel (恶性)     | 113  | 0.442 | 0.646 | +20 pt  |
| nv (良性, 大类)  | 674  | 0.905 | 0.904 | $\pm 0$ |
| vasc         | 15   | 1.000 | 1.000 | $\pm 0$ |

五个类别的召回率显著提升，其中临床意义最重要的黑色素瘤召回率从 0.442 提高到 0.646（提升 20 个百分点）。值得注意的是大类 nv 的召回率没有任何下降，其精确率反而从 0.865 升至 0.944——加权采样并没有“牺牲大类”：稀有类别学得更好之后，原本被误吸引到 nv 边缘的样本减少了。唯一没有变化的是 akiec（0.324，测试集仅 34 张），它与 bkl 在临床上属于连续谱系，是本数据集公认的难点。

### 4.3 混淆矩阵分析




图 3 基线模型混淆矩阵（行归一化）




图 4 改进版模型混淆矩阵（行归一化）

基线的混淆矩阵（图 3）呈现典型的“塌向 nv”模式：41.6% 的黑色素瘤被误判为痣，另有 11.5% 被判为良性角化病——这两部分恶性流失正是基线平衡准确率只有 0.615 的主因。改进版（图 4）将 mel 到 nv 的误判率砍半（41.6% 降至 21.2%）。残留的混淆集中在 akiec 与 bkl 之间（17.6% 升至 26.5%，两者本就是连续谱系）以及 bkl 与 mel 之间——这些是视觉上真正相似的类对，属于任务本身的难度，而非训练策略问题。

#### 4.4 训练过程




图 5 训练曲线：损失（左）与准确率（右）

从图 5 可以看到三点。第一，两个模型在第 5 个 epoch 时验证准确率接近（基线 0.693、改进版 0.704），但最终改进版达到 0.819 而基线止步于 0.776——预训练的价值体现在后期泛化而非前期收敛。第二，两个模型的训练准确率都显著高于验证准确率（改进版训练 0.983 对验证 0.812），说明在 8011 张图的规模下过拟合仍然

存在，强增强将其控制在了可接受范围（验证损失没有发散）。第三，改进版后期验证曲线在 0.80 至 0.82 之间小幅波动，这是加权采样下每个 epoch 类别组成随机性的正常表现，按验证准确率选最优权重即可。

## 4.5 消融说明与局限

本实验的改进是预训练、加权采样、强增强三项措施的打包对比，未逐一拆开做消融，这是本报告的局限之一。从机理推断：预训练贡献了大部分总体精度增益（文献共识），加权采样贡献了稀有类召回（平衡准确率提升的主要来源），强增强负责抑制过拟合。三项拆分验证的单次训练成本约 10 分钟，可作为后续工作快速补齐。此外，akiec 类别召回未获改善、测试集仅 1001 张图两项，也限制了对个别稀有类结论的置信度。

## 4.6 复现清单

全部流程可由仓库脚本复现：parquet\_extract.py 完成数据还原、官方清单过滤与按病灶分组划分；train.py 以相同种子分别训练基线与改进版；evaluate.py 输出指标文本、逐类报告、混淆矩阵与概率存档；plot\_curves.py 与 eda.py 生成训练曲线与探索性分析图。训练日志（outputs/\*/train\_log.csv）、逐图概率（outputs/\*/eval/probs.npz）与最优权重（outputs/\*/checkpoints/best.pth）均随实验保留。

## 五、改进方向

按投入产出比排序，后续可从以下五个方向继续改进：

1. 拆分消融与更强骨架：将三项改进逐一拆开验证各自贡献；再引入 ResNet50 或 EfficientNet 级别的骨干网络，在万级数据量下通常还能获得 2 至 3 个百分点的提升。
2. 针对性处理 akiec 与类谱系：akiec 与 bkl 属于连续谱系，单纯采样无法解决；可引入结构化损失（将 akiec 误分为 bkl 与误分为 nv 区别对待），或利用数据集的 dx\_type 字段（确诊手段）对标注不确定性加权。
3. 病灶级聚合预测：同一病灶的多张图目前独立预测；推理时按 lesion\_id 聚合概率后再判定，既符合临床流程（医生同样综合多张图判断），通常还能再提升 1 至 2 个百分点。
4. 测试时增强与阈值调优：对输入做翻转、旋转平均（TTA），并按验证集为各类别选择工作点，在可控精度损失下进一步提高黑色素瘤召回。
5. 可解释性分析：用 Grad-CAM 热力图展示模型关注的病灶区域，检查模型是否学

到了标尺、毛发等伪特征，这对医学应用的报告与审查很有说服力。

## 参考文献

- [1] Tschandl P., Rosendahl C., Kittler H. The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. Scientific Data, 2018.
- [2] He K., Zhang X., Ren S., Sun J. Deep Residual Learning for Image Recognition. CVPR, 2016.
- [3] Esteva A., Kuprel B., Novoa R. A., et al. Dermatologist-level classification of skin cancer with deep neural networks. Nature, 2017.
- [4] Bissoto V., Fornaciali M., Valle E., Lotufo R. Skin Lesion Image Segmentation and Classification: Survey and Benchmark. arXiv:1806.08234, 2018.